

Introduction aux fonctions de décision non-linéaires

Thierry Bazier-Matte

13 mai 2017

1 Algorithme de décision optimale

1.1 Formulations primale et duale

Tel que discuté en introduction, le cas le plus simple pour un espace de décision est celui où l'espace \mathbf{X} des variables de marché ne subit aucune transformation. L'espace \mathbf{Q} correspond¹ alors à \mathbf{X} et le scalaire de décision $q(x)$ est obtenu par produit scalaire $q^T x$. On obtient donc ici le problème sous la forme *primale* :

$$\boxed{\text{maximiser}_{q \in \mathbf{X}} \quad n^{-1} \sum_{i=1}^n u(r_i q^T x_i) - \frac{\lambda}{2} \|q\|^2} \quad (1)$$

Formulation primale I

Par la théorie de l'optimisation convexe (voir [?]) on sait qu'une solution \hat{q} existe et qu'elle est unique. En supposant que $\mathbf{X} \subseteq \mathcal{R}^p$, on peut alors exprimer \hat{q} comme une combinaison linéaire de p coordonnées.

Cependant, \hat{q} peut aussi être exprimé comme une combinaison linéaire de la base $\{x_1, \dots, x_n\}$, i.e. il existe un vecteur $\hat{\alpha} \in \mathcal{R}^n$ tel que $\hat{q} = \Xi^T \hat{\alpha}$, où $\Xi \in \mathcal{R}^{n \times p}$ est la matrice des observations.

Il suffit en effet de remarquer que l'espace $\mathbf{Q} = \mathbf{X}$ peut être décomposé comme la somme directe du sous-espace vectoriel $\hat{\mathbf{X}}$ engendré par Ξ^T et son complément orthogonal $\hat{\mathbf{X}}^\perp$, i.e. $\mathbf{Q} = \hat{\mathbf{X}} \oplus \hat{\mathbf{X}}^\perp$. Ainsi, tout vecteur de décision $q \in \mathbf{Q}$ s'exprime comme la somme de $\hat{x} \in \hat{\mathbf{X}}$ et $\hat{x}^\perp \in \hat{\mathbf{X}}^\perp$, deux vecteurs orthogonaux (voir les appendices de [?] ou [MRT12]). La fonction objectif EU_λ évaluée au point q se simplifie alors ainsi :

$$EU_\lambda(q) = EU_\lambda(\hat{x} + \hat{x}^\perp) \quad (2)$$

1. En fait, pour être exact, $q : \mathbf{X} \rightarrow \mathcal{R}$ étant une *fonction*, il est plus exact de faire correspondre \mathbf{Q} à l'espace *dual* \mathbf{X}^* . Mais par le théorème de Riez, à tout vecteur $v \in \mathbf{V}$ d'un espace vectoriel, il existe un unique vecteur dual $v^* \in \mathbf{V}^*$ (noté v^T en dimension finie). On peut donc se contenter de faire correspondre \mathbf{Q} à \mathbf{X} .

$$= n^{-1} \sum_{i=1}^n u(r_i (\hat{x} + \hat{x}^\perp)^T x_i) - \frac{\lambda}{2} \|\hat{x} + \hat{x}^\perp\|^2 \quad (3)$$

$$\leq n^{-1} \sum_{i=1}^n u(r_i \hat{x}^T x_i) - \frac{\lambda}{2} \|\hat{x}\|^2, \quad (4)$$

puisque, par définition, $(\hat{x}^\perp)^T x_i = 0$ pour toute observation x_i et que d'autre part $\|\hat{x}\|^2 \leq \|\hat{x}\|^2 + \|\hat{x}^\perp\|^2 = \|q\|^2$. Ainsi, toute solution \hat{q} repose bien dans l'espace colonne de Ξ^T .

Cette observation (qui correspond en fait au célèbre théorème de la représentation) peut se révéler très utile car elle permet de changer le domaine d'optimisation de \mathbf{X} à \mathcal{R}^n par l'identité $\hat{q} = \Xi^T \hat{\alpha}$. Autrement dit, le problème d'optimisation devient

$$\underset{\alpha \in \mathcal{R}^n}{\text{maximiser}} \quad n^{-1} \sum_{i=1}^n u(r_i \alpha^T \Xi x_i) - \frac{\lambda}{2} \alpha^T \Xi \Xi^T \alpha. \quad (5)$$

On peut simplifier cette expression en posant $K := \Xi \Xi^T \in \mathcal{R}^{n \times n}$:

$$\underset{\alpha \in \mathcal{R}^n}{\text{maximiser}} \quad n^{-1} \sum_{i=1}^n u(r_i K_i \alpha) - \frac{\lambda}{2} \alpha^T K \alpha, \quad (6)$$

Formulation duale I

où $\sum_{j=1}^n x_j^T x_i = K_i \in \mathcal{R}^n$ représente la i^{e} colonne (ou rangée car K est alors symétrique) de K . En fait K correspond à la *matrice gramienne*, i.e. la matrice des produits scalaires de toutes les observations x_i .

Le problème dual, lorsqu'il est exprimé avec une utilité risque neutre, admet une solution analytique équivalente à la solution primale, mais qui donne une interprétation supplémentaire au concept de solution optimale. En considérant

$$\underset{\alpha \in \mathcal{R}^n}{\text{maximiser}} \quad n^{-1} r^T K \alpha - \frac{\lambda}{2} \alpha^T K \alpha \quad (7)$$

et en faisant l'hypothèse qu'aucune observation x_i n'est de norme nulle (une telle observation serait de toute façon inutile puisqu'elle n'induirait alors aucune décision d'investissement, étant donné que $q^T x_i = 0$ pour toute décision q), K est alors définie positive et la solution $\hat{\alpha} = (\lambda n)^{-1} r$ est unique. Ainsi, la décision optimale $\hat{q} = \Xi^T \hat{\alpha}$ peut être conçue comme une moyenne pondérée par le rendement de chacune des observations.

1.2 Transformations non linéaires

Le cas $\mathbf{Q} = \mathbf{X}$ est cependant trop pour rendre compte de certaines géométries de problème. Il est alors naturel de définir une transformation non linéaire d'une observation $x \in \mathbf{X}$ par une fonction $\phi : \mathbf{X} \rightarrow \phi(\mathbf{X})$. Par exemple, si $\mathbf{X} \in \mathcal{R}$, i.e. une seule

variable de marché est considérée, alors on peut chercher une solution polynômiale en posant une transformation du genre

$$\phi : x \mapsto \begin{pmatrix} 1 \\ x \\ x^2 \\ \vdots \\ x^k \end{pmatrix}. \quad (8)$$

En notant $\langle \cdot, \cdot \rangle$ le produit scalaire de l'espace $\phi(\mathbf{X})$, le problème consiste alors à trouver un vecteur optimal $q \in \mathbf{Q} = \phi(\mathbf{X})$ de façon à

$$\boxed{\text{maximiser}_{q \in \phi(\mathbf{X})} \quad n^{-1} \sum_{i=1}^n u(r_i \langle q, \phi(x_i) \rangle) - \frac{\lambda}{2} \|q\|^2.} \quad (9)$$

Formulation primale II

Mais puisque le théorème de représentation s'applique encore, \hat{q} peut aussi s'exprimer comme une combinaison linéaire α des observations $\{\phi(x_1), \dots, \phi(x_n)\}$:

$$\boxed{\text{maximiser}_{\alpha \in \mathcal{R}^n} \quad n^{-1} \sum_{i=1}^n u(r_i K_i \alpha) - \frac{\lambda}{2} \alpha^T K \alpha.} \quad (10)$$

Formulation duale II

Cette fois par contre $K_{ij} = \langle \phi(x_i), \phi(x_j) \rangle$; chaque élément de K représente le produit scalaire dans le nouvel espace obtenu par transformation ϕ .

1.3 Fonctions de noyau

Ainsi, pour toute transformation $\phi : \mathbf{X} \rightarrow \phi(\mathbf{X})$, quelle que soit la dimension de l'espace $\phi(\mathbf{X})$, on peut exprimer la décision optimale à partir d'une optimisation sur n dimensions. En outre, ce programme d'optimisation ne dépend plus que du produit scalaire entre ces observations transformées. De plus, on peut dans bien des cas court-circuiter le calcul de ce produit scalaire par une fonction *noyau* $\kappa : \mathbf{X} \times \mathbf{X} \rightarrow \mathcal{R}$ telle que $\kappa(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$.

Par exemple, dans l'exemple montré plus haut, il suffirait de poser

$$\kappa(x_i, x_j) = 1 + x_i x_j + (x_i x_j)^2 + \dots + (x_i x_j)^k. \quad (11)$$

Évidemment, dans un pareil cas le gain est assez faible puisqu'on a uniquement réarrangé l'ordre des opérations. Mais, il est alors possible de circonvier complètement la transformation ϕ et de représenter sa non linéarité qu'à partir de κ . Par exemple, le noyau gaussien

$$\kappa(x_i, x_j) = \exp \left(-\frac{\|x_i - x_j\|^2}{2\sigma^2} \right) \quad (12)$$

permet de calculer directement le produit scalaire $\langle \phi(x_i), \phi(x_j) \rangle$ d'observations $\phi(x_i)$ et $\phi(x_j)$ de dimension infinie.

Choisir adéquatement le noyau est alors une tâche cruciale du modèle puisque tout noyau κ induit une géométrie particulière du modèle ; il peut alors être impossible de déterminer une fonction de décision q pourvue de bonne performance si le noyau ne correspond pas à la géométrie de la loi de marché M .

Il faut par ailleurs imposer une contrainte supplémentaire à la classe des noyaux possibles. En effet $\kappa(x_i, x_j)$ représente un produit scalaire dans $\phi(\mathbf{X})$ et est donc tenu de respecter les propriétés algébriques de celui-ci. En fait, κ doit satisfaire l'inégalité de Cauchy-Schwartz :

$$0 \leq \kappa(x_i, x_j)^2 = \langle \phi(x_i), \phi(x_j) \rangle^2 \quad (13)$$

$$\leq \|\phi(x_i)\| \|\phi(x_j)\| \quad (14)$$

$$= \kappa(x_i, x_i) \kappa(x_j, x_j). \quad (15)$$

Le noyau κ doit donc être une forme semi-définie positive sur \mathbf{X} (voir encore [MRT12]).

Références

- [KW71] George Kimeldorf and Grace Wahba. Some results on tchebycheffian spline functions. *Journal of mathematical analysis and applications*, 33(1) :82–95, 1971.
- [MRT12] Mehryar Mohri, Afshin Rostamizadeh, and Ameet Talwalkar. *Foundations of machine learning*. MIT press, 2012.